От дрожащего к рабочему: нейросетевой фильтр скелета для безмаркерного мокапа

Свёрточная сеть по времени, обученная на испорченном оптическом мокапе, против лучшего фильтра нижних частот на актёре, которого она не видела

Равиль Исхаков
Независимый технический аниматор



Рис. 1: Конвейер MoCap Studio. Оранжевая рамка — части, сделанные в этой работе, закрашенный блок — предмет статьи; 2D-точки и триангуляция используют готовые модели и Pose2Sim. Фильтр работает на готовом скелете, поэтому его результат сразу возвращается во вращения суставов и в сцену Maya.

АННОТАЦИЯ

Безмаркерный захват с нескольких телефонов даёт скелет, который дрожит, уплывает по глубине, скользит стопами и на несколько кадров путает левые и правые конечности. Фильтр нижних частот убирает дрожь, но срезает и быстрые движения, ради которых аниматору нужен мокап. Мы обучаем свёрточную сеть по времени на 608 тыс. параметров, которая видит ±64 кадра (±2,1 с) скелета из 19 суставов и предсказывает поправку к каждому суставу. Обучение идёт на чистом оптическом мокапе (LAFAN1, актёры 1–4), испорченном моделью ошибок безмаркерного захвата: дрожь, уплывание тела и суставов, скольжение стоп, короткие скачки и перепутанные лево и право, затем сглаживание 6 Гц, как в конвейере. Обучение занимает 3 минуты на одной RTX 4080. На актёре, которого сеть не видела (13 дублей, 89 853 кадра), средняя ошибка суставов падает с 4,40 до 3,46 см при среднем шуме и с 11,64 до 7,33 см при сильном, ошибка ускорений — в 2,2–3,2 раза, перепутанные стороны почти исчезают, а кисти и стопы сохраняют 98–99 % пиковой скорости. Лучший подобранный фильтр Баттерворта почти не снижает ошибку (4,38 и 11,46 см) и срезает пики стоп до 93 и 85 %. Очищенные положения переводятся обратно во вращения с неизменными длинами костей и уходят в Maya. На двух настоящих дублях с телефонов выигрыш меньше (дрожь −10…−13 %), а у стоящего актёра фильтр сдвигает стопы, которые солвер прибил к полу; это главная нерешённая проблема.

1 ВВЕДЕНИЕ

Оптическому мокапу нужны площадка, костюмы и маркеры; безмаркерному — только камеры. Платой для аниматора становится шум. Наш инструмент MoCap Studio снимает актёра на два–четыре телефона, находит 2D-точки, триангулирует их через Pose2Sim [9], подгоняет анатомический скелет с постоянными длинами костей и пишет сцену Maya (рис. 1). Скелет получается рабочим, но не чистым: запястья дрожат, таз уплывает вдоль направления взгляда камер, стоящие стопы скользят, а когда одна конечность закрывает другую, 2D-детектор на несколько кадров путает левую и правую.

Обычный ответ — фильтр Баттерворта без сдвига фазы [13]. С дрожью он справляется, но у него одна ручка — частота среза: низкая сглаживает удары, прыжки и постановку стоп, высокая оставляет шум. Ошибки, которые не являются высокочастотными, — перепутанную конечность или медленное уплывание — он не исправляет вовсе. Нам нужен был фильтр, который сохраняет быстрые движения, исправляет такие ошибки, работает за секунды и обучается без эталона с нашего собственного захвата.

В статье описан такой фильтр и честно измерен. Вклад работы:

- модель шума безмаркерного захвата, наложенная на чистый оптический мокап, — чтобы обучать и проверять сеть против правды;
- небольшая остаточная сеть по времени на скелете в системе курса актёра, обученная со слагаемыми на положения, скорости и ускорения;
- перевод очищенных положений обратно во вращения суставов с неизменными длинами костей, чтобы результат оставался скелетом, который аниматор может править;
- сравнение с лучшим подобранным фильтром Баттерворта на незнакомом актёре и на двух настоящих дублях без эталона, включая то, где фильтр ошибается.

2 СВЯЗАННЫЕ РАБОТЫ

Очистка мокапа. Holden [3] обучает сеть на данных оптических маркеров с искусственным шумом и восстанавливает чистые трансформы суставов; мы следуем той же идее порчи чистого мокапа, но портим готовый скелет так, как это делает безмаркерный захват. Holden и соавт. [4] строят многообразие движений свёрточным автокодировщиком и в том числе убирают им шум.

Таблица 1: Модель шума. Дрожь и уплывание суставов умножаются по суставам на 0,8 (таз, позвоночник)…1,5 (голова, запястья, голеностопы, носки).

Ошибка	Средний	Сильный
Дрожь, σ	1,2 см	2,5 см
Уплывание тела, ниже 0,5 Гц	2 см	5 см
Уплывание суставов, ниже 0,7 Гц	1 см	2,5 см
Скорость скольжения стоп, ниже 1,5 Гц	6 см/с	27 см/с
Всплески (5–15 кадров, 5–25 см)	4 / мин	12 / мин
Перепутаны лево/право (2–8 кадров)	1 %	3 %
Итоговый фильтр нижних частот	6 Гц	6 Гц

SmoothNet [15] уточняет покадровые оценки позы из видео сетью по времени. **Свёртки по времени.** Свёртки с расширением видят длинное окно при малой цене [12]; VideoPose3D [10] поднимает ими последовательности 2D-точек в 3D. Наша сеть того же типа, но стоит после триангуляции и солвера. **Безмаркерный захват.** Pose2Sim [9] триангулирует 2D-точки с откалиброванных камер; RTMPose [5] и Sapiens [6] — 2D-модели, которые мы используем. Чистка скольжения стоп давно известна в анимации [7]; раздел 7 показывает, почему она нужна и после нашего фильтра. **Данные.** LAFAN1 [2] — открытый набор оптического мокапа пяти актёров от Ubisoft La Forge; он служит чистым источником.

3 ДАННЫЕ И МОДЕЛЬ ШУМА

Чистые данные. В LAFAN1 77 дублей пяти актёров, 30 кадр/с. Обучаем на 53 дублях актёров 1–4 (333 571 кадр, 3,1 ч), проверяем на каждом шестом дубле тех же актёров (11 дублей, 73 248 кадров), тестируем на всех 13 дублях актёра 5 (89 853 кадра), которого сеть не видит. Каждый кадр сводится к 19 суставам нашего солвера: таз, две точки позвоночника, шея, голова, плечи, локти, запястья, тазобедренные суставы, колени, голеностопы и носки. Точки позвоночника стоят на 40 и 75 % пути от таза к шее.

Случайные тела. Каждый дубль используется восемь раз. Одна копия сохраняет исходное тело и не получает шума, чтобы сеть училась и не трогать чистое движение. Остальные семь получают новое тело: масштаб 0,85–1,25, ноги 0,93–1,07, позвоночник 0,9–1,25, голова 0,6–1,3, плечевой пояс 0,75–1,3, плечи 0,8–1,6, предплечья 0,92–1,15 и кисти 0,95–1,35 от исходных; точки позвоночника сдвигаются на 33–45 и 66–80 % пути таз–шея.

Модель шума. Таблица 1 перечисляет ошибки, которые мы добавляем к положениям суставов, в таком порядке: белая дрожь, сильнее на голове, запястьях и стопах; медленное уплывание всего тела и каждого сустава; скольжение каждой стопы как проинтегрированная окрашенная скорость; короткие всплески на 5–15 кадров, когда сустав прыгает на 5–25 см, как при перекрытии; перестановка левой и правой руки или ноги на 2–8 кадров. В конце последовательность проходит тот же фильтр нижних частот без сдвига, что и в нашем конвейере. Обучающие копии получают случайный уровень — сильный, умноженный на $t \sim U(0; 1{,}3)$, — и случайную частоту среза 4–9 Гц. Тест идёт на двух фиксированных уровнях, среднем и сильном, оба со срезом 6 Гц (рис. 2).

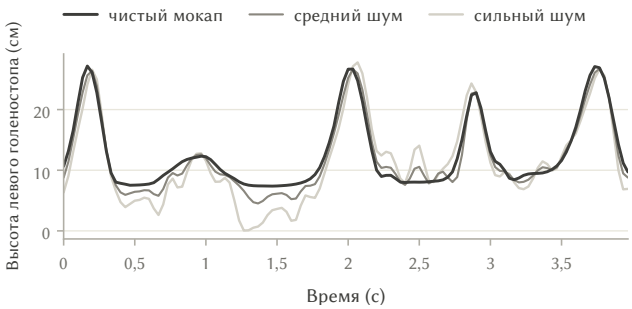


Рис. 2: Два тестовых уровня на левом голеностопе в ходьбе тестового актёра. Скольжение, всплески и уплывание меняют высоту опоры; итоговый фильтр 6 Гц сглаживает дрожь.

4 СЕТЬ И ОБУЧЕНИЕ

Вход. Сеть видит скелет в системе, которая поворачивается вместе с актёром. Курс — перпендикуляр к горизонтальной линии между тазобедренными суставами, сглаженный на 2 Гц. На кадр приходится 58 чисел: 18 суставов относительно таза в системе курса, скорость таза в той же системе и высота таза. Вход нормируется средним и разбросом обучающих данных.

Сеть. Свёртка 1×1 поднимает вход до 128 каналов. Дальше шесть остаточных блоков: свёртка с расширением и ядром 5, GroupNorm [14] на восемь групп, GELU, dropout 0,1 и свёртка 1×1; расширения 1, 2, 4, 8, 16 и 1 дают окно ±64 кадра. Последняя свёртка 1×1 выдаёт поправку к каждому из 19 суставов в системе курса, в единицах 5 см. Её веса стартуют с нуля, поэтому необученная сеть ничего не меняет. У сети 607 801 параметр.

Функция потерь. Если e_t — разница между предсказанной и истинной поправкой в кадре t, потери на окне равны

$$\mathcal{L} = \overline{\|e_t\|^2} + 2\,\overline{\|e_t - e_{t-1}\|^2} + 4\,\overline{\|e_t - 2e_{t-1} + e_{t-2}\|^2}, \qquad (1)$$

то есть штрафуются ошибки положения, скорости и ускорения.

Обучение. AdamW [8] (скорость 10^{-3}, затухание весов 10^{-2}) с расписанием one-cycle [11] и разгоном 5 %, пакеты из 64 окон по 128 кадров, ограничение градиента 1 и зеркало лево–право у половины окон. Обучение идёт 30 000 шагов, 3,0 минуты на RTX 4080. Каждые 2 500 шагов сеть оценивается на проверочных дублях по средней ошибке суставов плюс 0,2 ошибки ускорений; лучшая оценка пришлась на последний шаг, и ошибка на проверке ещё падала (рис. 3).

Применение. Дубль из 1 076 кадров фильтруется за 0,08 с на четырёх потоках процессора. Дубли с другой частотой кадров пересчитываются в 30 кадр/с и обратно.

5 ОБРАТНО ВО ВРАЩЕНИЯ СУСТАВОВ

Аниматору нужны вращения, а не точки. Мы считаем прямую кинематику скелета от солвера, фильтруем положения 19 суставов и поворачиваем каждую кость кратчайшим поворотом так, чтобы она смотрела на очищенного «ребёнка»; скрутка вокруг кости остаётся от солвера. Таз и грудь дополнительно доворачиваются по очищенным линиям бёдер и плеч, таз встаёт в очищенное положение. Длины костей не меняются. Проверка: если в качестве цели подать неотфильтрованные положения,

Таблица 2: Незнакомый актёр (LAFAN1, актёр 5, 13 дублей). Ошибка: среднее расстояние суставов до чистого мокапа. Ускор.: средняя ошибка ускорений. Пик: 99-й процентиль скорости относительно чистого мокапа.

Шум	Метод	Ошибка (см)	Корпус, голова	Руки	Ноги	Ускор. (мм/кадр^2)	Пик запястий	Пик стоп	Пик таза
Средний	Зашумлённый вход	4,40	3,74	4,41	4,80	9,76	127 %	105 %	101 %
	Баттерворт, 3 Гц	4,38	3,69	4,37	4,82	5,23	100 %	93 %	98 %
	ML-фильтр	**3,46**	**2,97**	**3,41**	**3,82**	**4,52**	98 %	99 %	99 %
Сильный	Зашумлённый вход	11,64	9,19	10,80	13,80	19,78	177 %	127 %	106 %
	Баттерворт, 2 Гц	11,46	9,05	10,59	13,62	6,38	93 %	85 %	96 %
	ML-фильтр	**7,33**	**6,51**	**7,44**	**7,77**	**6,25**	98 %	98 %	99 %

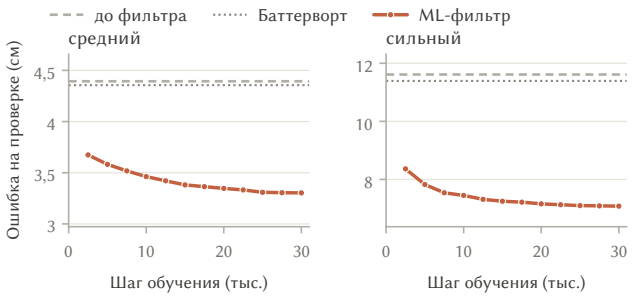


Рис. 3: Ошибка на проверке во время обучения. Штрихи — зашумлённый вход; точки — лучший фильтр Баттерворта. К 30 000 шагов кривая ещё снижается.

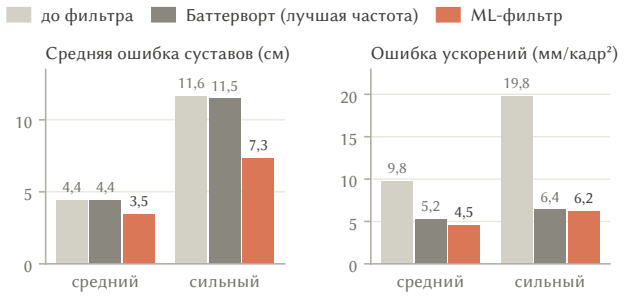


Рис. 4: Средняя ошибка суставов и ошибка ускорений на незнакомом актёре.

вращения меняются меньше чем на 10^{-9} градуса, длины костей — меньше чем на 10^{-7} мм. Результат пишется в том же формате скелета и сценой Maya.

6 РЕЗУЛЬТАТЫ НА НЕЗНАКОМОМ АКТЁРЕ

Протокол. Сравниваем зашумлённый вход, лучший фильтр Баттерворта и наш фильтр на всех 13 тестовых дублях. Частота среза Баттерворта подобрана на проверочных дублях по той же оценке, что и у сети: 3 Гц для среднего и 2 Гц для сильного шума. Ошибки считаются против чистого мокапа: средняя ошибка суставов, средняя ошибка ускорений и пиковая скорость как 99-й процентиль скорости относительно чистого дубля: 100 % — резкость сохранена, меньше — срезана, больше — добавлены лишние рывки.

Точность. Итоги — в таблице 2 и на рис. 4. Фильтр снижает среднюю ошибку суставов на 21 % при среднем и на 37 % при сильном шуме; улучшаются и корпус, и руки, и ноги. Баттерворт снижает её меньше чем на 2 %: большая часть ошибки — уплывание, всплески и перепутанные стороны, которые фильтр нижних частот убрать не может.

Плавность и резкость. Оба фильтра снижают ошибку ускорений, при сильном шуме примерно одинаково (6,38 и 6,25 мм/кадр^2). Разница в том, что они сохраняют: Баттерворт срезает пиковую скорость стоп до 93 и 85 %, сеть сохраняет 98–99 % у запястий, стоп и таза. На рис. 5 — фрагмент драки: сеть повторяет удары, которые шум размазал.

Перепутанные стороны. Считаем кадры, где запястье или голеностоп оказывается ближе к истинному положению противоположного, среди кадров, где истинные левый и правый дальше 15 см друг от друга. Таких кадров становится меньше: с 1,07 до 0,02 % при среднем и с 5,63 до 0,37 % при сильном шуме.

Устойчивость. Улучшается каждый из 13 тестовых дублей — от ходьбы и бега до драки, танца и подъёма с

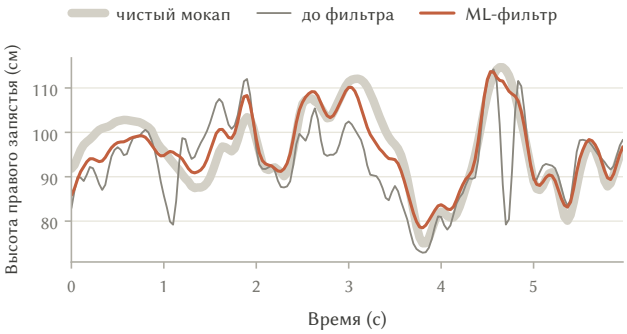


Рис. 5: Высота правого запястья в драке тестового актёра, сильный шум, 6 с.

пола (рис. 6). Ошибка после фильтра — от 3,29 до 3,74 см при среднем и от 6,92 до 7,92 см при сильном шуме.

7 НАСТОЯЩИЕ ДУБЛИ С ТЕЛЕФОНОВ

У настоящих дублей нет эталона, поэтому дрожь мы меряем как среднюю величину второй разности положений суставов, пиковую скорость — как 99-й процентиль скорости, и ещё смотрим, насколько фильтр сдвигает суставы. Взяты два дубля, обработанные MoCap Studio солвером Б: открытая запись FreeMoCap [1] «classroom» с точками Sapiens2-1B (1 076 кадров) и наш дубль *orest_2*: два телефона под углом 34°, точки RTMPose-x, актёр стоит на месте и крутит палку (871 кадр).

Что становится лучше. На обоих дублях успокаиваются корпус и руки (таблица 3): дрожь корпуса падает на 16 и 24 %, рук — на 9 и 14 %. Общий выигрыш, 10–13 %, намного меньше, чем на тесте: собственные ограничения и сглаживание солвера уже убрали большую часть дрожи, а настоящие ошибки не совпадают с нашей моделью шума. Пиковая скорость запястий падает на 7–12 %; без эталона нельзя сказать, какая часть — снятый шум, а какая — срезанное

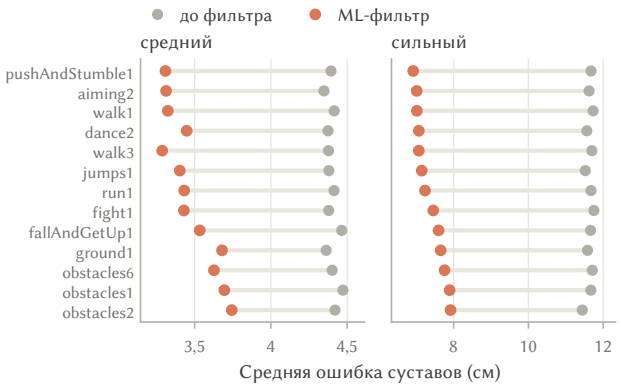


Рис. 6: Средняя ошибка суставов по тестовым дублям до и после фильтра. Ни один дубль не стал хуже.

Таблица 3: Настоящие дубли без эталона. Дрожь: средняя вторая разность положений суставов (мм/кадр^2), до → после фильтра.

	Classroom	orest_2
Дрожь, все суставы	3,34 → 3,00	1,56 → 1,36
корпус, голова	2,20 → 1,85	1,13 → 0,86
руки	4,08 → 3,71	2,99 → 2,56
ноги	3,49 → 3,20	0,75 → 0,78
Пик скорости запястий (м/с)	5,08 → 4,72	1,72 → 1,52
Пик скорости стоп (м/с)	4,10 → 3,70	1,05 → 1,22
Средний сдвиг суставов (см)	2,81	2,40

движение.

Что ломается: стоящие стопы. В *orest_2* актёр стоит на месте, и фиксация стоп в солвере держит голеностопы в пределах 0,2 см 28 секунд. После фильтра голеностопы уходят до 5 см от своего места и движутся в среднем со скоростью 7 см/с вместо 0,15, а дрожь ног на стоячей части растёт на 35 % (рис. 7). Сеть ничего не знает о контакте с полом: идеально неподвижную стопу она считает обычным суставом и добавляет к ней свои небольшие поправки. Решение — снова прибивать стопы после фильтра; в MoCap Studio уже есть поиск контактов и IK ног для экспорта в Maya, но эти два шага пока не связаны.

8 ОГРАНИЧЕНИЯ И ДАЛЬНЕЙШАЯ РАБОТА

Модель шума составлена вручную по тому, что мы видим в своих дублях; она не измерена против эталона с нашей установки, и разрыв между тестом и настоящими дублями показывает, что она неполна. LAFAN1 — одна студия и один стиль захвата; пальцы не покрыты. Фильтр ничего не знает о контакте стоп — это его главная практическая слабость. Обучение было коротким, и ошибка на проверке ещё падала. Дальше мы хотим добавить контакт на вход и выход сети, обучать дольше и записать свои дубли вместе с эталоном: со стельками с датчиками давления для контакта и, где получится, с оптическим мокапом.

9 ЗАКЛЮЧЕНИЕ

Небольшая сеть по времени, обученная за три минуты на чистом оптическом мокапе с моделью ошибок безмаркерного захвата, убирает треть ошибки, которую добавляет сильный шум, и почти все перепутанные стороны, сохраняя быстрые движения, которые срезает

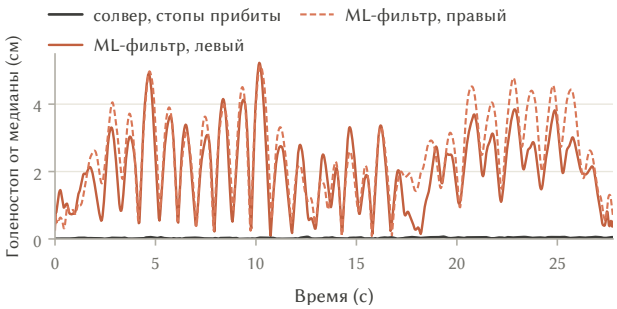


Рис. 7: *orest_2*: расстояние голеностопов по горизонтали от их медианного положения, пока актёр стоит. Солвер держит стопы на месте, фильтр заставляет их уплывать.

фильтр нижних частот. Её результат возвращается во вращения суставов и в Maya без изменения скелета. На настоящих дублях с телефонов она успокаивает корпус и руки, но после неё нужно снова прибивать стопы.

БЛАГОДАРНОСТИ

LAFAN1 предоставлен Ubisoft La Forge по лицензии CC BY-NC-ND 4.0. Запись «classroom» — пример FreeMoCap. Код написан с помощью ИИ-ассистента (Claude, Anthropic).

СПИСОК ЛИТЕРАТУРЫ

[1] FreeMoCap Foundation. FreeMoCap: free and open-source markerless motion capture. https://github.com/freemocap/freemocap.
[2] Félix G. Harvey, Mike Yurick, Derek Nowrouzezahrai and Christopher Pal. 2020. Robust Motion In-betweening. *ACM Transactions on Graphics* 39, 4.
[3] Daniel Holden. 2018. Robust Solving of Optical Motion Capture Data by Denoising. *ACM Transactions on Graphics* 37, 4.
[4] Daniel Holden, Jun Saito and Taku Komura. 2016. A Deep Learning Framework for Character Motion Synthesis and Editing. *ACM Transactions on Graphics* 35, 4.
[5] Tao Jiang, Peng Lu, Li Zhang, Ningsheng Ma, Rui Han, Chengqi Lyu, Yining Li and Kai Chen. 2023. RTMPose: Real-Time Multi-Person Pose Estimation based on MMPose. arXiv:2303.07399.
[6] Rawal Khirodkar, Timur Bagautdinov, Julieta Martinez, Su Zhaoen, Austin James, Peter Selednik, Stuart Anderson and Shunsuke Saito. 2024. Sapiens: Foundation for Human Vision Models. In *ECCV*.
[7] Lucas Kovar, John Schreiner and Michael Gleicher. 2002. Footskate Cleanup for Motion Capture Editing. In *Symposium on Computer Animation*.
[8] Ilya Loshchilov and Frank Hutter. 2019. Decoupled Weight Decay Regularization. In *ICLR*.
[9] David Pagnon, Mathieu Domalain and Lionel Reveret. 2022. Pose2Sim: An open-source Python package for multiview markerless kinematics. *Journal of Open Source Software* 7, 77.
[10] Dario Pavllo, Christoph Feichtenhofer, David Grangier and Michael Auli. 2019. 3D Human Pose Estimation in Video with Temporal Convolutions and Semi-supervised Training. In *CVPR*.
[11] Leslie N. Smith and Nicholay Topin. 2019. Super-Convergence: Very Fast Training of Neural Networks Using Large Learning Rates. arXiv:1708.07120.
[12] Aäron van den Oord, Sander Dieleman, Heiga Zen, Karen Simonyan, Oriol Vinyals, Alex Graves, Nal Kalchbrenner, Andrew Senior and Koray Kavukcuoglu. 2016. WaveNet: A Generative Model for Raw Audio. arXiv:1609.03499.
[13] David A. Winter. 2009. *Biomechanics and Motor Control of Human Movement* (4th ed.). Wiley.
[14] Yuxin Wu and Kaiming He. 2018. Group Normalization. In *ECCV*.
[15] Ailing Zeng, Lei Yang, Xuan Ju, Jiefeng Li, Jianyi Wang and Qiang Xu. 2022. SmoothNet: A Plug-and-Play Network for Refining Human Poses in Videos. In *ECCV*.